



PROYECTO INTEGRADOR
Análisis de Sensibilidad de Hiperparámetros

Profesora	GLADYS MARIA VILLEGAS RUGEL
Materia	PROYECTO INTEGRADOR EN INTELIGENCIA ARTIFICIAL
Alumnos	Bolaños Escandón María Fernanda Montaño Cárdenas Fernando Xavier
Fecha	21/10/2025

Contenido

REPORTE DE ANÁLISIS DE HIPERPARÁMETROS — Proyecto ClinicCareAI.....	1
1. Resumen Ejecutivo	1
2. Análisis de Sensibilidad Individual.....	1
3. Ranking de Importancia.....	2
4. Interacciones Críticas.....	2
5. Plan de Acción en Fases.....	3
6. Tabla Comparativa Antes/Después	3
7. Conclusiones y Reflexiones.....	3
REFERENCIAS	4

REPORTE DE ANÁLISIS DE HIPERPARÁMETROS — Proyecto ClinicCareAI

Autores:
 Bolaños Escandón María Fernanda
 Montaña Cárdenas Fernando Xavier

Fecha: 21/10/2025

1. Resumen Ejecutivo

El modelo predictivo implementado en el proyecto *ClinicCareAI* busca anticipar descompensaciones clínicas en pacientes con diabetes tipo 2, hipertensión o ambas, utilizando aprendizaje supervisado y datos clínicos tabulares enriquecidos con *Data Augmentation* y balanceados mediante SMOTE.

Se aplicó una búsqueda aleatoria *RandomizedSearchCV* [1] para optimizar los hiperparámetros del modelo *RandomForestClassifier* sobre una submuestra representativa de 198 983 registros. La configuración base del modelo obtuvo un F1-macro de 0.9547, mientras que la mejor combinación encontrada presentó un F1 de 0.9357, confirmando la robustez y estabilidad del modelo actual, sin mejoras relevantes mediante ajuste fino. El análisis de sensibilidad e interacciones demuestra que el modelo es poco sensible a variaciones de hiperparámetros, siendo `max_depth` el único parámetro crítico.

2. Análisis de Sensibilidad Individual

Se evaluaron seis hiperparámetros: `n_estimators`, `max_depth`, `min_samples_split`, `min_samples_leaf`, `max_features`, y `criterion`.

Los resultados del análisis F1 promedio en validación cruzada [2] se resumen así:

Hiperparámetro	Patrón observado	Sensibilidad	Comparación con actual
<code>n_estimators</code>	F1 estable; sin mejora clara	Baja	300 árboles = zona óptima
<code>max_depth</code>	Limitarlo reduce F1 significativamente	Crítica	None (sin límite) óptimo
<code>min_samples_split</code>	F1 cae al aumentar el valor	Moderada	Valor óptimo: 2
<code>min_samples_leaf</code>	F1 desciende al subir el valor	Moderada	Valor óptimo: 1
<code>max_features</code>	“sqrt” y “log2” casi iguales	Baja	“sqrt” mantiene F1 máximo
<code>criterion</code>	“gini” y “entropy” idénticos	Baja	“gini” óptimo

El único hiperparámetro crítico es `max_depth`, pues controla la complejidad del modelo. Los demás muestran variaciones menores (<2 % en F1), confirmando la estabilidad general del Random Forest.

3. Ranking de Importancia

A partir del meta-modelo `RandomForestRegressor`, se determinó la importancia relativa de cada hiperparámetro en la predicción del rendimiento F1 macro [3]:

Ranking	Hiperparámetro	Importancia (%)	Clasificación	Acción
1	<code>max_depth</code>	85.18 %	Crítico	Mantener sin límite (None)
2	<code>min_samples_split</code>	8.58 %	Moderado	Mantener 2–3
3	<code>min_samples_leaf</code>	3.31 %	Moderado	Mantener 1
4	<code>criterion</code>	1.22 %	Bajo	Mantener “gini”
5	<code>n_estimators</code>	0.05 %	Bajo	Mantener 300

El parámetro `max_depth` domina el comportamiento del modelo ($\approx 85\%$), confirmando que su ajuste define la capacidad de aprendizaje y el control del sobreajuste.

4. Interacciones Críticas

Se analizaron las combinaciones con mayor sinergia entre hiperparámetros:

Interacción	Tipo	Descripción	Conclusión
<code>max_depth</code> vs <code>min_samples_split</code>	Sinérgica	Profundidad alta (15–20) + split bajo (2–4) mejora F1	La configuración actual (<i>None</i> , 2) ya se encuentra en el óptimo
<code>min_samples_split</code> vs <code>min_samples_leaf</code>	Condicional	Mejores resultados con ambos parámetros bajos	Mantener <i>split=2</i> , <i>leaf=1</i>

Los *heatmaps* confirman que el modelo alcanza su máximo F1 (~ 0.95) con la configuración actual; no se obtienen mejoras al variar estos parámetros. Se puede confirmar revisando el nootebook.

5. Plan de Acción en Fases

Fase	Acción	Objetivo	Estado
1	Mantener la configuración actual del modelo	Preservar el rendimiento y la estabilidad alcanzada con $F1 \approx 0.95$.	Implementada con éxito; el modelo está operativo en su versión estable.
2	Reentrenar con el dataset completo (900 000 registros)	Aumentar la robustez del modelo y la cobertura de patrones clínicos.	En planificación; pendiente de ejecución con mayor capacidad computacional.
3	Validar con datos clínicos reales hospitalarios	Comprobar la generalización del modelo en entornos reales.	En fase de diseño; se coordinará con instituciones de salud para pruebas controladas.
4	Monitorear el rendimiento y el drift del modelo	Detectar posibles degradaciones y garantizar la consistencia a largo plazo.	En desarrollo; se implementará un sistema de seguimiento continuo post-despliegue.

6. Tabla Comparativa Antes/Después

Configuración	F1 Macro	Accuracy	Precision	Recall	Diferencia (%)
Modelo base (n_estimators=300, max_depth=None)	0.9547	0.9545	0.9555	0.9547	—
Mejor configuración encontrada	0.9357	0.935	0.937	0.935	-1.99 %

La configuración actual ofrece mejor equilibrio entre precisión y generalización, mostrando que el modelo ya opera en una zona de estabilidad óptima.

7. Conclusiones y Reflexiones

- El modelo Random Forest balanceado con SMOTE demuestra alta precisión ($F1 \approx 0.95$) y baja sensibilidad a hiperparámetros, confirmando su robustez clínica.
- El ajuste de hiperparámetros no mejora significativamente el rendimiento, lo que indica que la configuración base está optimizada.
- El análisis de interacciones y sensibilidad respalda la fiabilidad del modelo para su futura integración en la plataforma *ClinicCareAI*, enfocada en predicción temprana de descompensaciones crónicas.
- A futuro, se recomienda incorporar modelos híbridos (Random Forest + LSTM) para capturar mejor la evolución temporal de las variables fisiológicas.
- El análisis de importancia mostró que limitar max_depth a 10 explica ≈ 85 % de la variación en el rendimiento, lo que indica su alta sensibilidad. Sin embargo, no significa que sea el valor óptimo, sino que esa restricción genera la mayor degradación. Por tanto, mantener max_depth=None ofrece una configuración más estable y precisa.

REFERENCIAS

- [1] Scikit-learn Developers, *RandomizedSearchCV Documentation*, v1.5.2, 2025.
- [2] Kuhn, M., & Johnson, K., *Applied Predictive Modeling*, Springer, 2022.
- [3] Pedregosa et al., *Scikit-learn: Machine Learning in Python*, JMLR, 2011.