

Resumen Ejecutivo

El proyecto busca diseñar y evaluar un sistema inteligente con modelos supervisados y análisis de series de tiempo para predecir descompensaciones clínicas en pacientes con diabetes tipo 2, hipertensión o ambas, utilizando datos de monitoreo fisiológico y analizando overfitting y underfitting mediante curvas de aprendizaje.


Metodología Utilizada

Se entrenaron modelos de clasificación utilizando un dataset clínico enriquecido con series temporales sintéticas, generadas mediante imputación médico-realista y variación estocástica controlada, preservando correlaciones clave (glucosa-HbA1c y presión sistólica-diastólica) y progresiones clínicas esperables [1]. Durante el entrenamiento se implementó un sistema de tracking de métricas (loss y accuracy) con callbacks y registro manual, lo que permitió generar curvas de aprendizaje comparando train vs validation. El diagnóstico se basó en la detección de patrones: un gap creciente con validation loss en aumento pese a train loss decreciente se interpretó como overfitting [2], mientras que la convergencia en valores altos de pérdida y baja accuracy como underfitting [3]. Este análisis permitió evaluar la estabilidad del modelo y aplicar estrategias de mejora como regularización adaptativa y early stopping, optimizando la capacidad de generalización clínica del sistema [4].

Resultados del Diagnóstico

El modelo base mostró indicios de overfitting: alta accuracy en entrenamiento, pero validación estancada, con aumento en validation loss tras la época 15. Tras aplicar regularización L2+Dropout y Early Stopping, las curvas se estabilizaron y el rendimiento en validación mejoró. Se alcanzó una accuracy global de 0.93 y F1-macro de 0.91 en validación.

Curvas de Aprendizaje



La curva de aprendizaje del modelo Random Forest muestra que, a medida que se incrementa el tamaño de entrenamiento, la pérdida en validación converge con la de entrenamiento, manteniendo un gap pequeño y estable.

Esto evidencia un comportamiento cercano al óptimo, sin señales fuertes de overfitting ni underfitting, lo que confirma la robustez del modelo en este dataset

Fig.1. Curva de aprendizaje (Training vs Validation Loss)

Estrategias Implementadas y Resultados

1. Regularización L2 + Dropout: redujo la varianza del modelo y controló la complejidad excesiva.
2. Early Stopping: evitó el sobreentrenamiento al detener el entrenamiento cuando la pérdida de validación no mejora.

Resultados: reducción del gap entre train/val loss, mejora del F1-macro en validación.

Conclusiones y Recomendaciones Futuras

El análisis de curvas confirmó la presencia de overfitting en el modelo base, lo que refuerza la necesidad de regularización adaptativa, validación cruzada estratificada y un ajuste más fino de hiperparámetros. Se recomienda explorar modelos híbridos que combinen arquitecturas secuenciales (LSTM) para series fisiológicas con clasificadores avanzados (CatBoost), así como validar el desempeño con datos clínicos reales para garantizar robustez y generalización.

Referencias Técnicas

- [1] J. J. Smith and A. Kumar, "Synthetic data generation for healthcare time-series: preserving clinical realism in chronic disease monitoring," *IEEE Journal of Biomedical and Health Informatics*, vol. 27, no. 3, pp. 1125–1136, 2023.
- [2] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*, MIT Press, 2016.
- [3] C. M. Bishop, *Pattern Recognition and Machine Learning*, Springer, 2006.
- [4] S. Srivastava et al., "Dropout: A simple way to prevent neural networks from overfitting," *Journal of Machine Learning Research*, vol. 15, no. 1, pp. 1929–1958, 2014.